

La navaja de Ockham aplicada a la predicción deportiva y el triunfo del modelado lineal sobre la complejidad

José Vicente Sánchez Montilla

Dpto. Ciencias de la Computación e Inteligencia Artificial
Universidad de Sevilla
Sevilla, España
jossanmon1@alum.us.es, CGD5709

Diego José Rodríguez Fernández

Dpto. Ciencias de la Computación e Inteligencia Artificial
Universidad de Sevilla
Sevilla, España
dierodfer1@alum.us.es, NCQ5239

Resumen—El presente trabajo tiene como objetivo principal desarrollar, optimizar y evaluar modelos predictivos de aprendizaje automático para anticipar los resultados de partidos de fútbol (victoria local, empate o victoria visitante). Debido al alto grado de incertidumbre y ruido estadístico inherente a este deporte, el estudio propone una metodología robusta de ciencia de datos centrada en la ingeniería de características avanzadas y el análisis de adaptación de dominio (utilizando el histórico de LaLiga española y la Premier League inglesa). Para garantizar el rigor metodológico y evitar el crítico fenómeno de fuga de datos (*Data Leakage*), se ha implementado una arquitectura de evaluación estrictamente cronológica, la cual permite a los algoritmos asimilar el volumen histórico reproduciendo fielmente las restricciones temporales de un entorno real.

Las conclusiones empíricas obtenidas tras la evaluación aislada revelan un fenómeno fundamentado en la paradoja de la complejidad: frente a la alta estocasticidad del fútbol, la restricción matemática supera consistentemente a las arquitecturas complejas puras. Específicamente, la Regresión Logística sometida a una fuerte regularización restrictiva demostró ser el filtro algorítmico más eficaz contra el ruido estadístico. Sin embargo, la estrategia de despliegue final evidenció que el techo predictivo exige adaptación al dominio: mientras que la predicción de la Premier League alcanzó su máximo con la aplicación pura del modelo lineal, en LaLiga se logró la máxima métrica global integrando un ensamblado de *Soft Voting* entre Regresión Logística y XGBoost. Estos resultados confirman una lección clave para entornos impredecibles como el del fútbol: la aproximación óptima consiste en combinar la seguridad y firmeza de un modelo simple con la agudeza de un modelo avanzado, asegurando siempre que ambos aprendan de un conjunto de variables de altísima calidad.

Palabras clave—Machine Learning, Series Temporales, Data Leakage, Dominio Cruzado, Feature Engineering, Fútbol, Regresión Logística, PCA.

I. INTRODUCCIÓN

En la era contemporánea del Big Data, el análisis del rendimiento deportivo ha evolucionado desde la observación estadística básica hacia el modelado predictivo complejo. A diferencia de disciplinas con alta puntuación como el baloncesto, el fútbol se caracteriza por ser un deporte de marcador extremadamente bajo. Esta particularidad incrementa drásticamente el factor estocástico de los encuentros,

dificultando la extracción de patrones deterministas [1]. La predicción de la variable objetivo clásica (victoria local, empate o victoria visitante) resulta un desafío analítico profundo debido a la influencia de la evolución táctica, el estado de forma a corto plazo y la alta dimensionalidad de los factores contextuales.

Para abordar esta incertidumbre, la literatura académica reciente ha adoptado de forma generalizada técnicas de aprendizaje automático (*Machine Learning*) aplicadas a grandes bases de datos históricas. No obstante, una deficiencia metodológica recurrente en aproximaciones menos rigurosas es la aplicación de técnicas de validación cruzada aleatoria sobre series con una fuerte dependencia temporal [2]. Esta práctica desencadena el crítico fenómeno de Data Leakage, permitiendo que los modelos incorporen implícitamente información del futuro para predecir el pasado, lo que genera un falso buen rendimiento en el entrenamiento e invalida su aplicabilidad en escenarios reales.

El objetivo principal de este trabajo es subsanar dichas carencias mediante el desarrollo de un sistema predictivo altamente robusto, generalizable y aislado de sesgos temporales. Se propone una arquitectura metodológica evaluada sobre dos de las competiciones más exigentes a nivel global: LaLiga y la Premier League. Para lograrlo, el problema se aborda de forma secuencial, incidiendo de manera crítica en la ingeniería de variables, la comparativa de dominios cruzados entre ambas ligas y la prevención del sobreajuste en modelos de diversa complejidad.

El resto de este documento se organiza de la siguiente manera: la Sección II introduce los conceptos preliminares y los algoritmos candidatos elegidos para el estudio. La Sección III detalla el proceso de enriquecimiento de datos y la ingeniería de variables. La Sección IV fundamenta la metodología de evaluación temporal y la prevención de fugas de información. La Sección V presenta las decisiones de diseño arquitectónico y el análisis de dominio, seguida por la Sección VI, que expone los resultados de la optimización paramétrica avanzada y el impacto de las características mediante PCA. Finalmente, la Sección VII recoge las conclusiones definitivas del estudio.

II. PRELIMINARES Y ALGORITMOS CANDIDATOS

El desarrollo de este sistema predictivo se plantea matemáticamente como un problema de clasificación multi-clase ($y \in \{1, X, 2\}$). Lejos de presentar una distribución uniforme, la ventaja de jugar en casa introduce un severo desbalanceo de clases que condiciona tanto la configuración matemática de los algoritmos como la métrica de evaluación elegida. Para abordar la complejidad de este entorno, se ha diseñado una metodología secuencial. Antes de establecer la lista de modelos candidatos, escalonados desde métodos probabilísticos lineales hasta arquitecturas profundas, se llevó a cabo un exhaustivo Análisis Exploratorio de Datos. El objetivo de esta fase inicial fue comprender las dinámicas estadísticas propias del fútbol para establecer las reglas y necesidades fundamentales de la posterior ingeniería de variables:

A. Análisis exploratorio inicial

- **El problema del "nombre del equipo":** Se llegó a la conclusión de que utilizar el nombre del club como variable predictora directa es ineficaz y propenso al sobreajuste debido a la rotación de equipos por ascensos y descensos y a la extensa amplitud temporal de los datos (2000-2024). Por ejemplo, si los modelos aprendieran que el Sevilla suele ganar siempre al ser entrenado con datos de 2015, fracasará estrepitosamente al predecir partidos de 2023. Este problema podría intentar solucionarse utilizando una ventana temporal más pequeña para el entrenamiento, pero como se explicará en la Sección V, esto empeora en gran medida los modelos. Además, la inclusión de los nombres va en contra de una de las principales motivaciones del proyecto: queremos que el modelo aprenda sobre los patrones tácticos y generalizables del fútbol, no que memorice resultados de equipos. Otro inconveniente de la inclusión de los nombres de los clubes es que habría que codificarlos utilizando *Label Encoding* o *One-Hot Encoding*, y teniendo en cuenta que entre LaLiga y la Premier hay alrededor de 40 equipos, se incrementaría drásticamente la dimensionalidad del espacio de características. Se requiere por tanto traducir el "nombre" a métricas de rendimiento que permitan al modelo evaluar el estado de forma real de cualquier equipo de forma anónima y generalizable.
- **Rendimiento en casa vs visitante:** Los datos evidenciaron, como era de esperar, un sesgo sistemático hacia la victoria local [Fig. 1], justificando la futura separación de estadísticas (por ejemplo, goles marcados como local y como visitante).
- **Rendimiento acumulado y estado de forma:** El análisis confirmó visualmente que los picos de rendimiento a corto plazo (rachas recientes) y la acumulación histórica a lo largo de la temporada se correlacionan fuertemente con la probabilidad de victoria.

B. Modelos utilizados

- 1) **Regresión Logística y Random Forest (Modelos Básicos):** La Regresión Logística es un modelo es-




Fig. 1. Diagrama de disparidad en las victorias como local y visitante.

tadístico lineal que estima probabilidades pasando una combinación lineal de las variables a través de una función logística (específicamente la función *Softmax* para nuestro escenario multiclase). En cambio, el *Random Forest* crea múltiples árboles de decisión independientes y promedia sus respuestas para mitigar la varianza. Debido a su bajo coste computacional y menor grado de abstracción, son los elegidos como línea base para determinar los parámetros generales a utilizar, como se desarrollará en la Sección V.

- 2) **XGBoost y LightGBM (Modelos Avanzados):** Se consolidan como los algoritmos de referencia en la actualidad por su superioridad en el análisis de datos estructurados. Se basan en la técnica de *Gradient Boosting*, un enfoque iterativo que construye árboles de decisión de forma secuencial, donde cada nuevo árbol se entrena específicamente para aprender y corregir los errores residuales que cometieron los estimadores anteriores [3].
- 3) **Perceptrón Multicapa o MLP (Modelos Avanzados):** Es una arquitectura clásica de Red Neuronal Artificial compuesta por múltiples capas de neuronas interconectadas. Destaca por su capacidad para modelar funciones no lineales y encontrar representaciones ocultas y complejas en las variables deportivas, detectando patrones que los modelos basados en reglas o árboles podrían pasar por alto.

III. ADQUISICIÓN, ENRIQUECIMIENTO E INGENIERÍA DE CARACTERÍSTICAS

El éxito del modelo sobre los datos depende en su mayoría de la calidad y robustez de las variables de entrada, por lo que se le dio especial importancia a esta fase. Además, decidimos realizar una búsqueda de datos externos para enriquecer los datos de entrenamiento que nos proporcionaron para incorporar dimensiones adicionales, como factores económicos o métricas avanzadas de las plantillas que no estaban presentes en el conjunto original.

A. Exploración y enriquecimiento de datos externos

Como explicamos en la sección anterior, el análisis exploratorio inicial demostró la ineficacia de utilizar el propio

”Nombre del equipo” como variable predictora, además de evidenciar fuertes sesgos en el rendimiento en casa frente al desempeño a domicilio.

Para subsanarlo, se integraron fuentes de datos externas. Específicamente, se recurrió a un extenso repositorio público alojado en la plataforma Kaggle [4], el cual compila y estructura información detallada proveniente de Transfermarkt [5], reconocida como la principal base de datos global sobre economía y estadística del fútbol profesional. Este dataset se componía de varios archivos csv relacionados entre sí, con datos sobre las lesiones de los jugadores, valor de los mismos, equipos en los que jugaron, traspasos, entre otras cosas, desde aproximadamente el 2003 hasta el 2025. Si bien existe una falta de datos para los registros más antiguos (2000-2003), el impacto de esta ausencia es mínimo, dado que la mayor parte del conjunto de entrenamiento y la totalidad de las temporadas de validación (2023-2024 y 2024-2025) cuentan con información completa.

El reto principal de esta integración radicó en homogeneizar la nomenclatura de los clubes entre las distintas bases de datos. Para ello, recurrimos a soluciones de fuerza bruta: utilizamos la herramienta de Inteligencia Artificial Google Antigravity IDE (con el agente Gemini 3.1 Pro) para que analizara los archivos csv externos y los que se nos proporcionaron, construyendo con éxito posteriormente un extenso diccionario que ”mapea” los nombres de los equipos en el csv de entrenamiento con los de los csv externos. Superado este obstáculo, se procedió a construir variables contextuales clave:

- **Valor de la plantilla al inicio de la temporada:** Un indicador del poderío económico e institucional del club. Se diseñó para evitar el *Data Leakage*, asignando el valor de la plantilla estrictamente en el instante en el que arranca la temporada. Para que no se produjera filtración de datos en ninguna jornada temprana, se estableció el 1 de agosto como fecha límite para contar los traspasos (y por tanto no se tienen en cuenta fichajes realizados al final del verano o del mercado de invierno).
- **Altura media y edad media de la plantilla:** Variables biométricas y de madurez táctica asociadas al rendimiento general del equipo. Pueden parecer inútiles, sobre todo la altura, pero en ciencia de datos nunca se sabe el impacto real que puede tener una variable aparentemente intrascendente hasta que se prueba.
- **Número y coste de jugadores lesionados:** Dos variables críticas para capturar el estado de la plantilla. Se contabilizó la cantidad de jugadores ausentes por lesión y su valor de mercado combinado, introduciendo en el modelo el impacto económico y deportivo de las ausencias antes de cada partido.

Siendo la estructura de datos del csv relativamente compleja, nos apoyamos en inteligencia artificial generativa para la integración de estas nuevas variables de manera adecuada sin provocar data leakage ni cálculos erróneos.

B. Preparación y limpieza de datos

Antes de generar variables complejas a partir del csv proporcionado, se requirió una base sólida y codificada matemáticamente. En esta etapa se llevaron a cabo tres procesos fundamentales:

En primer lugar, se aplicó un tratamiento temporal a la información. Se convirtieron las fechas de los partidos a un formato estándar (datetime) y se ordenó todo el dataset de forma cronológica. Este paso es vital para asegurar que las variables acumulativas que se diseñarán a posteriori nunca se calculen empleando información de partidos futuros, evitando así cualquier posible fuga de datos.

A continuación, se procedió a la **codificación de la variable objetivo**. El resultado clásico de los encuentros (1, X, 2) se mapeó a una variable numérica discreta (denominada `resultado_cod`), habilitando de esta manera su procesamiento matemático directo por parte de los algoritmos de Machine Learning.

Finalmente, se diseñó un **sistema de puntuación auxiliar**. Para ello, se crearon variables transitorias (`puntos_local` y `puntos_visitante`) que otorgan 3, 1 o 0 puntos dependiendo del resultado final del partido. Estas columnas no se emplearon como predictoras directas (ya que indicarían directamente al modelo quién ha ganado), sino que sirvieron como apoyo matemático para facilitar los cálculos en la siguiente fase de la ingeniería de variables.

C. Preparación y generación de variables

Tras el preprocesado explicado anteriormente, se programó un sistema de generación de variables para dotar de inercia temporal a los datos crudos. Las podemos agrupar en 3 grupos:

- **Acumulados de la temporada:** Se extrajeron el total de puntos conseguidos (`pts_acum`) y la diferencia de goles general (`dif_goles_acum`) que arrastraba cada equipo desde el inicio del año hasta la jornada actual.
- **Rachas Recientes:** Para medir el estado de forma a corto plazo, se calcularon ventanas móviles de los últimos N partidos (ventanas de 3 y 5 encuentros). De esta ventana temporal se extrajeron: los puntos sumados en ese tramo (`pts_ultimos_N`), el promedio de goles a favor (`gf_media_N`) y el promedio de goles en contra (`gc_media_N`).
- **Rendimiento específico local/visitante:** Se programó un sistema para calcular la fortaleza específica de los equipos en el estadio. Por un lado, se calculó el promedio de puntos del equipo local cuando juega exclusivamente en su campo (`promedio_pts_casa`). Por otro lado, se calculó el promedio de puntos del equipo visitante cuando actúa *exclusivamente* como visitante. (`promedio_pts_fuera`).

IV. METODOLOGÍA DE VALIDACIÓN Y PREVENCIÓN DE FUGA DE DATOS

La evaluación de modelos predictivos en eventos secuenciales, como los partidos de fútbol, exige un diseño de validación estrictamente cronológico debido a la dependencia

temporal de los datos. En este escenario, el uso de técnicas de partición aleatoria convencionales (como K-Fold Cross-Validation) provocaría de forma inevitable un fenómeno de fuga de datos, invalidando el experimento al permitir que los algoritmos utilicen información del futuro para predecir el pasado. Para garantizar la validez científica y la capacidad de generalización de los resultados, se ha diseñado una infraestructura de validación temporal estructurada en las siguientes fases:

A. Prevención de Data Leakage mediante censura

El Data Leakage ocurre cuando las características de entrenamiento contienen información que no estaría disponible en el momento de la predicción en el mundo real. Para evitar la invalidación del experimento, durante la fase de modelado se aplicó un protocolo de limpieza estricto: columnas como el resultado definitivo o los puntos derivados directamente del partido a predecir fueron eliminadas de la matriz de características.

B. Walk-Forward Validation

Para evaluar los modelos sin alterar el orden temporal, se desechó la validación cruzada tradicional, ya que su partición aleatoria habría destruido la causalidad de la serie temporal. En su lugar, implementamos una validación cronológica estricta denominada *Walk-Forward Validation*, como se nos indicó en la norma del proyecto. Como se ilustra en la Fig. 2, esta técnica garantiza que el algoritmo solo se entrene con eventos estrictamente anteriores a los encuentros que debe predecir.




Fig. 2. Esquema de validación para series temporales (walk forward validation) con ventana expansiva.

C. Implementación de herramientas personalizadas

Para implementar la metodología de validación descrita, se ha desarrollado un módulo de utilidades propio (`src/model_utils.py`), dado que las implementaciones estándar proporcionadas por la librería Scikit-Learn no cubrían las necesidades estructurales y de evaluación específicas del dominio del problema. A continuación, se detallan las dos funciones implementadas:

Validación temporal por temporadas completas: La herramienta nativa `TimeSeriesSplit` de Scikit-Learn realiza las particiones temporales basándose estrictamente en el número de filas. Aplicar este enfoque a datos futbolísticos resulta problemático, ya que dividir el dataset a mitad de

una temporada introduce sesgos analíticos evidentes, ignorando sucesos importantes como los cambios de plantilla y de objetivos que ocurren durante el mercado de fichajes de verano. Para solucionar esto, se implementó la función `walk_forward_split`. Esta función obliga al algoritmo a realizar los cortes de validación utilizando la variable `anio_fin_temporada`, garantizando que los modelos siempre se entrenen y evalúen empleando bloques de temporadas completas. Además, la función soporta tanto ventanas de entrenamiento expansivas (*expanding*) como deslizantes (*sliding*), para poder determinar la cantidad de temporadas utilizadas al entrenar.

Evaluación de métricas multiclase: La evaluación de los modelos exige el cálculo del *F1-score* (para las etiquetas de clase) y del Área Bajo la Curva de Precisión-Exhaustividad o *AUC-PR* (para las probabilidades), ambas en su variante macro. Mientras que el cálculo del *F1-score* es directo, el cómputo del *AUC-PR* en problemas multiclase (1, X, 2) no se procesa de forma automática en Python. Por ello, se desarrolló la función `calculate_metrics`, la cual binariza internamente las etiquetas reales mediante un proceso de One-Hot Encoding. Esta transformación permite extraer una medida precisa de la probabilidad de acierto para cada clase de forma independiente y promediarlas, obteniendo el rendimiento global.

Cabe destacar que, para la implementación técnica de estas funciones, nos hemos apoyado en herramientas de inteligencia artificial generativa (en concreto, el modelo Gemini). No obstante, todo el código generado ha sido exhaustivamente revisado, validado y asimilado por ambos miembros del equipo, asegurando su total comprensión de cara a la defensa y su correcta integración en el proyecto final.

V. DECISIONES DE ENTRENAMIENTO INICIALES

Esta fase se centró en probar hipótesis arquitectónicas mediante los modelos "básicos" indicados en la Sección 2 (Regresión Logística y Random Forest), estableciendo el diseño final y los parámetros generales a utilizar antes de comenzar con el entrenamiento definitivo de los modelos.

A. Ventana temporal y modelo base dominante

En las pruebas preliminares, la validación temporal expansiva (que acumula todo el historial pasado) superó holgadamente a la validación deslizante, demostrando que la táctica histórica no añade ruido, sino contexto útil. Asimismo, la Regresión Logística demostró una gran superioridad frente a Random Forest en las combinaciones iniciales.

B. Métodos de selección de características e importancia de las variables

Se exploró la viabilidad de utilizar técnicas de reducción de dimensionalidad y selección de características, específicamente el Análisis de Componentes Principales (PCA) y el Sequential Feature Selector (SFS), con el objetivo de mitigar el sobreajuste y filtrar información redundante. Tras la experimentación empírica, se comprobó que los modelos predictivos

de la Premier League se beneficiaban significativamente de la transformación mediante PCA, mientras que los modelos de LaLiga maximizaban su rendimiento al mantener el espacio de variables original.

Dado que el modelo con mejor desempeño (entrenado exclusivamente con la liga inglesa) empleó PCA, se aprovechó su estructura matemática para analizar la importancia real de las características originales. Para contextualizar este análisis, es preciso recordar que el PCA es un algoritmo de reducción de dimensionalidad centrado en preservar la varianza de los datos, entendida esta como su "información" o capacidad discriminativa. En lugar de descartar variables, el algoritmo realiza una transformación lineal hacia un nuevo sistema de coordenadas ortogonales. Así, cada nueva componente (PC1, PC2, etc.) captura secuencialmente la dirección de máxima varianza restante que no fue capturada por las anteriores. En nuestro pipeline, el sistema se configuró para retener un 95% de la varianza total del conjunto original.

Apoyándonos en este fundamento geométrico, se implementó una métrica de importancia ponderada para calcular el impacto real de cada variable original. Cabe destacar que, para la definición, estructuración algorítmica y entendimiento de esta métrica, se contó con la asistencia de modelos de inteligencia artificial generativa, en concreto de nuevo de Gemini 3.1 Pro. En primer lugar, se extrajo la matriz de coeficientes de PCA y se elevó al cuadrado para aislar la magnitud absoluta de la contribución de cada variable, neutralizando así el efecto de los signos. A continuación, dado que las componentes no aportan la misma cantidad de información, estas magnitudes se ponderaron multiplicándolas por el ratio de varianza explicada de su respectiva componente principal. Finalmente, la suma de estos valores proporcionó un ranking global de importancia, cuyos resultados revelaron patrones analíticos de gran valor Fig. 3:

- **El físico sobre las rachas:** Sorprendentemente, los atributos físicos (altura media y edad media de la plantilla) lideraron el ranking predictivo en la Premier League, reflejando estadísticamente un estilo de juego caracterizado por la alta intensidad y el dominio aéreo. Por el contrario, las métricas de estado de forma a corto plazo, como las rachas de los últimos 5 partidos, quedaron relegadas a la parte inferior de la tabla.
- **Distribución uniforme de la varianza:** El análisis de los pesos ponderados mostró una distribución extremadamente homogénea. La característica más determinante retenía un 3.56% del peso predictivo, frente al 3.25% de la variable teóricamente menos relevante. Esta diferencia marginal de apenas un 0.31% confirma el éxito de la fase de ingeniería de variables, demostrando que no se introdujeron características inútiles, es decir, todas aportaron información discriminativa.

C. Separación de dominios

La evaluación preliminar de los modelos reveló discrepancias significativas en la predictibilidad de ambas competiciones. Los modelos entrenados y evaluados exclusivamente




Fig. 3. Ranking de impacto de las variables.

en la Premier League demostraron un rendimiento superior, dominando la parte alta de la tabla con un AUC-PR máximo de 0.4829. Por el contrario, LaLiga presentó un entorno estadísticamente más ruidoso y complejo de modelar, obteniendo apenas un 0.4643 al usar modelos exclusivos.

Al entrenar un modelo global unificado, se alcanzó un AUC-PR general de 0.4756. Sin embargo, para evitar un falso espejismo métrico donde la facilidad matemática para predecir la liga inglesa inflara artificialmente el promedio, ocultando un posible empeoramiento en la predicción española, se planteó una hipótesis de adaptación de dominio: ¿aporta el histórico inglés valor real a la predicción de LaLiga?

Para despejar esta incógnita, se entrenó un modelo con la historia completa de ambas competiciones, pero su rendimiento se evaluó estricta y exclusivamente sobre los partidos de LaLiga. Para la estructuración de este experimento se utilizó de nuevo Inteligencia Artificial generativa, sobre todo para poder determinar cómo evaluar la métrica AUC-PR solo sobre cierta parte de los datos. Los resultados de este análisis de dominios fueron:

El modelo unificado evaluado únicamente sobre España obtuvo un AUC-PR de 0.4709, superando holgadamente el 0.4643 del modelo puramente nacional. Queda demostrado que la inyección de los datos ingleses no introduce ruido, sino que aporta un volumen estadístico positivo. Esto permite al algoritmo generalizar mejor y asimilar patrones universales del deporte, mejorando su precisión dentro del dominio español.

Por lo tanto, para obtener los mejores resultados posibles, se decidió que para evaluar la Premier League se implementará un modelo específico para dicha competición y que por el contrario, para predecir los encuentros de LaLiga, se empleará un único modelo global.

Además, para garantizar el rigor científico y la reproducibilidad exacta de los experimentos, se aplicó una política de inicialización fijando una semilla global (42 arbitrariamente). Esto bloqueó la aleatoriedad en las librerías del sistema operativo. Igualmente, todos los algoritmos y particiones de datos instanciados incluyeron el parámetro `random_state = 42`, asegurando que cualquier proceso produzca resultados idénticos en ejecuciones sucesivas.

VI. OPTIMIZACIÓN Y SELECCIÓN DE MODELOS

Una vez consolidada la arquitectura de validación y la ingeniería de variables, se procedió a la fase de entrenamiento. El objetivo fue identificar el equilibrio óptimo entre los hiperparámetros de los diferentes modelos indicados en la Sección 2. La optimización de hiperparámetros se ejecutó mediante una búsqueda en rejilla (con *GridSearchCV*), acoplada a la métrica objetivo *AUC-PR macro* y respetando las decisiones explicadas en la sección anterior.

A. Modelos básicos

La experimentación inicial evaluó algoritmos de Regresión Logística y Random Forest.

Los resultados coronaron a la Regresión Logística como el algoritmo superior. En el entorno aislado de la Premier League alcanzó un AUC-PR de 0.4853, mientras que el modelo global evaluado estrictamente sobre LaLiga logró un 0.4723. En ambas configuraciones, el optimizador convergió hacia un hiperparámetro de regularización sumamente restrictivo ($C = 0.01$) y descartó cualquier reducción de dimensionalidad en contra de nuestras hipótesis de la última sección. Esta fuerte penalización matemática confirma la naturaleza estocástica del dominio: el algoritmo requiere el máximo nivel de generalización para evitar la memorización de anomalías y forzar el aprendizaje de patrones de juego generales. De igual forma, el Random Forest respaldó esta hipótesis al limitar sus árboles a una profundidad máxima baja (`max_depth=5`).

B. Modelos avanzados y la paradoja de la complejidad

Posteriormente, se introdujeron algoritmos de vanguardia diseñados para capturar relaciones no lineales y estructuras latentes: XGBoost, LightGBM y Redes Neuronales Densas (MLP).

En contra de nuestras previsiones, se comprobó lo siguiente: los algoritmos más sofisticados presentaron un rendimiento inferior a los más básicos (al menos para los datos de entrenamiento). El modelo más destacado de esta segunda fase fue XGBoost, obteniendo un AUC-PR máximo de 0.4627 para Inglaterra y 0.4534 para España.

El análisis de los hiperparámetros seleccionados revela la justificación matemática de este declive, un escenario conocido como la paradoja de la complejidad, un fenómeno documentado extensamente bajo el concepto de la ilusión del progreso [6]. XGBoost seleccionó la arquitectura más rudimentaria posible (`max_depth=1`), es decir, que el propio optimizador restringió drásticamente la profundidad estructural de los árboles para intentar emular la rigidez de un

modelo lineal simple. Por su parte, el Perceptrón Multicapa (MLP) obtuvo el desempeño más deficiente de todos los candidatos. Esto demuestra empíricamente que las arquitecturas profundas sufren problemas de sobreajuste y convergencia prematura al enfrentarse a la aleatoriedad de los marcadores del fútbol profesional, donde intentar modelar el ruido destruye la generalización futura.

En la siguiente tabla se pueden observar los rangos dentro de los cuáles se movían los diferentes hiperparámetros para cada algoritmo:

TABLA I
ESPACIO DE BÚSQUEDA DE HIPERPARÁMETROS

Algoritmo	Espacio de búsqueda
Regresión Logística	$C \in \{(0.01, 0.1, 1.0, 10.0)\}$
Random Forest	$model_n_estimators \in \{50, 100, 200\}$ $model_max_depth \in \{1e-4, 1e-3, 1e-2\}$
XGBoost	$n_estimators \in \{50, 100\}$ $max_depth \in \{1, 3, 5\}$ $learning_rate \in \{0.01, 0.1\}$
MLP	$hidden_layers \in \{(50,), (100,), (50, 50)\}$ $\alpha \in \{1e-4, 1e-3, 1e-2\}$
LightGBM	$n_estimators \in \{50, 100\}$ $max_depth \in \{3, 5\}$ $learning_rate \in \{0.01, 0.1\}$

Los modelos generados fueron exportados como archivos .pkl para ser consumidos y reutilizados en el cuaderno final del proyecto.

VII. EVALUACIÓN FINAL Y CONCLUSIONES

Para validar empíricamente los hallazgos de la fase de optimización y preparar las candidaturas definitivas para la competición, se procedió a evaluar los algoritmos ganadores frente a un conjunto de prueba completamente nuevo para los modelos (correspondiente a las temporadas 2023-2024 y 2024-2025). El objetivo de esta fase fue doble, ya que debíamos certificar la capacidad de generalización real sobre datos futuros y explorar sinergias matemáticas mediante técnicas de ensamblado para intentar obtener aún mejores resultados.

A. Confirmación de la paradoja de la complejidad

La evaluación individual sobre el conjunto de prueba corroboró, de forma contundente, la superioridad de los enfoques probabilísticos lineales en dominios de alta estocasticidad. En la Premier League, la Regresión Logística alcanzó un excelente AUC-PR Macro de 0.5009, superando holgadamente a su contraparte no lineal (XGBoost, 0.4562). De igual modo, en LaLiga, el modelo lineal registró un 0.5051, batiendo de nuevo al algoritmo de Gradient Boosting (0.4973). Estos resultados definitivos confirman la hipótesis principal del proyecto: en un entorno tan impredecible como el fútbol, la simplicidad matemática es el mejor filtro contra el azar. Un modelo fuertemente restringido como la Regresión Logística con el parámetro $C = 0.01$, alimentado por variables contextuales

sólidas, es capaz de centrarse en la tendencia real de los equipos e ignorar la "suerte". Este enfoque resulta mucho más robusto que utilizar algoritmos complejos basados en árboles, los cuales fracasan al intentar crear reglas rebuscadas para justificar resultados que, en el fondo, son fruto del ruido estadístico.

B. Ensamblado de modelos

A pesar de la superioridad del enfoque lineal, se exploró la viabilidad de combinar las predicciones de la Regresión Logística y el XGBoost para aprovechar las fortalezas de ambos. Se descartó el uso de *Stacking* porque, en un entorno con tanto azar como el fútbol, crear un algoritmo que aprenda de los errores de otros modelos tiende a memorizar resultados fortuitos, provocando un fuerte sobreajuste. En su lugar, se optó por un *Soft Voting Ensemble*. Esta técnica calcula, de manera directa, la media aritmética de las probabilidades de ambos algoritmos. El objetivo de esta media es lograr un equilibrio, es decir, el modelo lineal, al ser más conservador, actúa como un ancla que impide al modelo XGBoost lanzar predicciones extremas o dejarse engañar por situaciones atípicas. A cambio, el árbol enriquece el resultado final aportando pequeños detalles tácticos que la rigidez del modelo lineal no es capaz de detectar.

Los resultados del ensamblado revelaron un comportamiento estrictamente dependiente del dominio de origen:

En cuanto a la Premier, el ensamblado obtuvo un 0.4880, quedando por debajo de la Regresión Logística pura. Al existir una brecha de rendimiento tan amplia entre ambos modelos base, la media aritmética actuó como un lastre, diluyendo la precisión del modelo. En el caso de LaLiga, el ensamblado alcanzó un sobresaliente 0.5099, superando a los dos algoritmos individuales. En el entorno táctico español, el modelo lineal y el basado en árboles lograron compensar mutuamente sus puntos ciegos estadísticos, generando la representación probabilística más exacta de todo el estudio.

C. Estrategia de despliegue y candidaturas definitivas

Con base en el análisis de rendimiento final, y con la intención de maximizar la puntuación predictiva en la plataforma de evaluación Kaggle, se decidió enviar 2 candidaturas o submissions diferenciadas:

- 1) **Candidatura Principal:** Une las predicciones de nuestros 2 mejores modelos, es decir, utiliza las probabilidades de la Regresión Logística pura para predecir los encuentros de la Premier League, mientras que despliega las predicciones combinadas del modelo de ensamblado para los partidos de LaLiga.
- 2) **Candidatura Alternativa:** Como en ciencia de datos no podemos dar nada por sentado, también enviamos la combinación de nuestros segundos mejores modelos. Esta solución invierte la arquitectura anterior: aplica el ensamblado conservador a la Premier League y utiliza la Regresión Logística pura para LaLiga, garantizando un rendimiento competitivo base y mitigando el riesgo de anomalías estadísticas imprevistas.

REFERENCIAS

- [1] R. T. Hughes and M. Franks, "Sports analytics: A review of the past, present and future," *International Journal of Sports Science & Coaching*, 2015.
- [2] D. Berrar and C. S. Lo, "Learning from imbalanced data in football match prediction," en *Proceedings of the 21st International Conference on Machine Learning (ICML)*, 2004.
- [3] T. Chen and C. Guestrin, "XGBoost: A Scalable Tree Boosting System," en *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016, pp. 785–794.
- [4] Kaggle, "Football Datasets - Player Performances.". Disponible en: <https://www.kaggle.com/datasets/xfkzujqjvx97n/football-da>
- [5] Transfermarkt, "Base de datos de fútbol profesional.". Disponible en: <https://www.transfermarkt.es/>.
- [6] D. J. Hand, "Classifier Technology and the Illusion of Progress," *Statistical Science*, vol. 21, no. 1, pp. 1-14, 2006.