



La Navaja de Ockham en la Predicción Deportiva

El triunfo del modelado lineal sobre la complejidad en la anticipación de resultados de fútbol profesional.

MACHINE LEARNING · SERIES TEMPORALES · FEATURE ENGINEERING

El Desafío Analítico del Fútbol

A diferencia del baloncesto, el fútbol es un deporte de marcador extremadamente bajo. Esta particularidad incrementa drásticamente el factor estocástico, dificultando la extracción de patrones deterministas y convirtiendo la predicción del resultado (victoria local, empate o visitante) en un reto analítico profundo.

Alta estocasticidad

Pocos goles generan ruido estadístico que enmascara los patrones reales de rendimiento.

Alta dimensionalidad

Factores contextuales múltiples: forma reciente, lesiones, táctica y ventaja de campo.

Desbalanceo de clases

La ventaja local introduce una distribución no uniforme en la variable objetivo.



Enriquecimiento de los Datos



Valor de plantilla

Poderío económico e institucional, asignado al inicio de temporada (corte: 1 de agosto).

Lesiones activas

Número y coste de mercado de jugadores ausentes antes de cada encuentro.

Rachas recientes

Ventanas móviles de 3 y 5 partidos: puntos, goles a favor y en contra.

Ingeniería de variables



Acumulados de temporada

Puntos totales (pts_acum) y diferencia de goles acumulada desde el inicio de la campaña hasta la jornada actual.



Rachas recientes

Estado de forma a corto plazo mediante ventanas móviles de los últimos 3 y 5 encuentros: puntos, goles a favor y en contra.




Rendimiento local/visitante

Promedio de puntos del equipo local en casa y del visitante fuera, capturando la fortaleza específica en cada contexto.


Prevención de Data Leakage: Validación Cronológica Estricta

El uso de validación cruzada aleatoria en series temporales permite que los modelos usen información del futuro para predecir el pasado, generando un **falso rendimiento** e invalidando la aplicabilidad real. La ventana expansiva acabó siendo la que mejor resultados dió.

⚠ La solución: **Walk-Forward Validation** con cortes por temporadas completas, garantizando que el algoritmo solo se entrena con eventos estrictamente anteriores a los encuentros que debe predecir.



PCA Revela: El Físico Domina en la Premier League



Atributos físicos lideran el ranking

Altura media y edad de la plantilla superaron a las rachas recientes, reflejando un estilo de juego de alta intensidad y dominio aéreo.

Distribución uniforme de la varianza

La variable más determinante retuvo solo el 3,56% del peso, frente al 3,25% de la menos relevante. Diferencia de apenas 0,31%: todas las características aportan información discriminadora.

Separación y Adaptación de Dominios

La evaluación inicial reveló diferencias en la predictibilidad de la Premier League y LaLiga. La Premier League, con menos ruido estadístico, alcanzó un AUC-PR máximo de 0.4829, mientras que LaLiga, más ruidosa, apenas llegó a 0.4643 con modelos nacionales. Esto planteó la necesidad de investigar si los datos cruzados podrían mejorar el rendimiento.

1

Discrepancia Inicial

La Premier League demostró ser más predecible (AUC-PR 0.4829) que LaLiga (AUC-PR 0.4643) con modelos exclusivos.

2

Hipótesis de Adaptación

¿Aportaría el histórico de la liga inglesa valor real a la predicción de LaLiga? Se planteó un modelo global unificado.

3

Impacto Positivo

El modelo unificado, evaluado exclusivamente en LaLiga, obtuvo un AUC-PR de 0.4709, superando al modelo puramente nacional.

4

Estrategia Final

Se decidió usar un modelo específico para la Premier League y un modelo global (entrenado con ambas ligas) para predecir LaLiga.

La inyección de los datos ingleses no solo no introdujo ruido, sino que aportó volumen estadístico positivo, permitiendo al algoritmo generalizar mejor y asimilar patrones universales del deporte, mejorando su precisión en el dominio español.

La Paradoja de la Complejidad

Los algoritmos más sofisticados **rendieron por debajo** de los más simples. XGBoost seleccionó `max_depth=1` y el MLP fue el peor candidato. La explicación: en entornos de alta aleatoriedad, modelar el ruido destruye la generalización futura.

Regresión Logística ($C=0.01$)


Máxima regularización restrictiva. Ignora anomalías, aprende tendencias generales.

XGBoost (`max_depth=1`)


El optimizador restringió drásticamente la profundidad para emular un modelo lineal.

MLP (Red Neuronal)

Peor desempeño global. Sobreajuste y convergencia prematura ante la aleatoriedad de los marcadores.



Resultados Definitivos: AUC-PR Macro en Test



Interpretación de los resultados

La Regresión Logística pura domina en la Premier League. En LaLiga, el **Soft Voting Ensemble** supera a ambos modelos individuales (0,5099), compensando mutuamente sus puntos ciegos estadísticos.

i La simplicidad matemática es el mejor filtro contra el azar. Un modelo fuertemente restringido ignora la «suerte» y se centra en la tendencia real de los equipos.

Estrategia de Despliegue y Conclusiones

1

Candidatura Principal

Regresión Logística pura para la **Premier League** + Soft Voting Ensemble para **LaLiga**. Máxima puntuación predictiva por dominio.

2

Candidatura Alternativa

Arquitectura inversa como respaldo: ensamblado en Premier y modelo lineal en LaLiga, mitigando el riesgo de anomalías estadísticas imprevistas.

3

Lección Fundamental

La aproximación óptima en entornos impredecibles combina la **seguridad del modelo simple** con la **agudeza del avanzado**, sobre variables de altísima calidad y sin fuga de datos.