

Competición de ciencia de datos: predicción de resultados de partidos de fútbol

Curso 2025/2026

Grado en Ingeniería Informática – Ingeniería del Software
Propuesta de trabajo práctico de la asignatura Inteligencia Artificial

Prof. Juan Galán Páez

1. Introducción y objetivo

La **ciencia de datos** es un campo interdisciplinar que combina estadística, programación y conocimiento del dominio para extraer información útil a partir de datos. Utiliza técnicas de análisis exploratorio, aprendizaje automático y visualización para descubrir patrones, hacer predicciones y apoyar la toma de decisiones. Abarca todo el **ciclo de vida del dato**, desde su recopilación y limpieza hasta el modelado y la interpretación de resultados.




Figura 1: Esquema general de un proyecto de ciencia de datos.

El **objetivo general** de este trabajo es que los estudiantes apliquen diferentes técnicas, algoritmos y herramientas para obtener **predicciones de resultados de partidos de fútbol**, siguiendo los pasos típicos de un proyecto de ciencia de datos (véase la Figura 1). Este objetivo puede descomponerse en una serie de hitos o tareas:

- Construir un conjunto de datos útil para entrenar y evaluar modelos predictivos de resultados de partidos, mediante:
 - Enriquecimiento de datos a partir de fuentes externas.
 - Ingeniería de variables temporales que permitan caracterizar la trayectoria de los equipos en cada momento.
- Diseñar un esquema de evaluación de modelos robusto que respete la naturaleza temporal de los datos. Es decir, debemos respetar el orden temporal entre los conjuntos de entrenamiento (pasado) y evaluación (futuro).

- Mejorar el rendimiento de los modelos de forma iterativa mediante ajuste de hiperparámetros e ingeniería y selección de variables.
- Participar en competiciones de Kaggle (específicas de este trabajo) en las que podrán comparar el rendimiento de sus modelos con los de otros estudiantes.
- Documentar el trabajo realizado usando un formato de artículo científico.
- Realizar una presentación (PDF, PowerPoint o similar) de los resultados obtenidos.

2. Recursos y metodología

Las posibilidades, a la hora de abordar el objetivo (obtener el mejor modelo posible para estimar resultados de partidos de fútbol), son prácticamente infinitas, tanto en el diseño del conjunto de datos como en la metodología de evaluación y optimización de modelos. Se trata, por tanto, de un **proyecto abierto**, en el que se espera que los alumnos pongan en práctica ideas creativas e innovadoras. A continuación se describen los principales elementos a tener en cuenta a la hora de abordar el trabajo.

2.1. Algoritmos y herramientas

Es posible abordar este proyecto usando únicamente las librerías de Python para ciencia de datos que se han visto en clase, NumPy, Pandas y Scikit-learn. Tanto para la parte de construcción del conjunto de datos, como para la parte de modelado y evaluación de modelos, deberá explorar las capacidades de estas librerías más allá de lo que se ha cubierto en clase. En lo que respecta al aprendizaje automático, existen algoritmos con mayor capacidad predictiva que los vistos en clase, además de técnicas de optimización más complejas y eficientes. Se espera que los estudiantes exploren técnicas, algoritmos y librerías más allá de las mencionadas.

Adicionalmente, recuerde que las redes neuronales representan una posibilidad más (sin ser un requisito) dentro de las técnicas de aprendizaje automático que se pueden usar. *Scikit-learn* ofrece una implementación de redes neuronales densas, aunque si quiere explorar arquitecturas más complejas debe recurrir a librerías como TensorFlow y *Keras*.

2.2. Conjunto de datos

Se proporciona un conjunto de datos base (archivo ***train.csv***) con información básica sobre partidos (extraída de la web football-data.co.uk). Como se puede observar, en la tabla 1, el conjunto de datos base contiene:

- Variables que identifican el partido: equipo local, equipo visitante, temporada, fecha, liga, id. Use la columna *año fin temporada* para identificar y seleccionar los partidos de una misma temporada.
- Variables que representan el resultado del partido: Goles del equipo local, Goles del equipo visitante y resultado $(1, X, 2)$.

El ámbito al que se acota el proyecto es el siguiente:

- Ligas: *Premier League* inglesa y *Primera División* española.
- Temporadas: Desde la temporada **2000-2001** hasta la temporada **2022-2023**.

Adicionalmente se proporciona un conjunto de datos (archivo ***test.csv***) que contiene datos de las temporadas más recientes 2023-2024 y 2024-2025 (y se proporcionarán los de la 2025-2026

Tabla 1: Conjunto de datos base

id	division	año fin temporada	fecha	local	visitante	goles local	goles visitante	resultado
10341-2223-ESP1	ESP LaLiga	2023	2023-06-04	Espanol	Almeria	3	3	X empate
10334-2223-ESP1	ESP LaLiga	2023	2023-06-04	Osasuna	Girona	2	1	1 local
10335-2223-ESP1	ESP LaLiga	2023	2023-06-04	Real Madrid	Ath Bilbao	1	1	X empate
10336-2223-ESP1	ESP LaLiga	2023	2023-06-04	Sociedad	Sevilla	2	1	1 local
10337-2223-ESP1	ESP LaLiga	2023	2023-06-04	Villarreal	Ath Madrid	2	2	X empate

más adelante), que se usarán para evaluar el rendimiento de los modelos desarrollados en la competición de *Kaggle* anteriormente mencionada.

Estos datos se proporcionan por separado ya que no deben usarse durante la selección y optimización de modelos. Solo debe usarlos para calcular las variables temporales (predictoras) de estos partidos y para entrenar los modelos finales con los que generar las predicciones de la competición. Por ejemplo, es posible que quiera incluir partidos de 2023-2024 en el conjunto de entrenamiento del modelo que usará para predecir los resultados de los partidos de 2024-2025.

Importante: Los datos pondrán descargarse desde la página de la competición. Si detecta cualquier error en los datos, póngase en contacto con el profesor.

2.3. Enriquecimiento con fuentes externas

Se proporciona un conjunto de datos base que solo contiene información sobre el resultado de los partidos. Aunque los datos proporcionados son suficientes, los estudiantes tienen total libertad para obtener información adicional sobre partidos o equipos, que les permita mejorar sus modelos. A continuación se realizan dos aclaraciones importantes sobre el uso de fuentes externas:

- **Reutilización de código y proyectos:** Está permitido y se recomienda la reutilización de proyectos existentes de descarga de datos a partir de fuentes públicas, **siempre que se cite convenientemente la fuente**. No es objetivo de este proyecto el desarrollo de sistemas de *web scraping*, y aunque se tendrá en cuenta todo el trabajo realizado, es preferible el uso de APIs públicas o códigos de extracción de datos existentes. Es importante no confundir la descarga de datos con el preprocesado y limpieza de variables que sí debe ser trabajo original de los estudiantes.
- **Fuentes de datos prohibidas:** No se permite el uso de **cuotas de casas de apuestas** como fuente de datos para este trabajo. Las cuotas (su inversa) representan la probabilidad que las casas de apuestas asignan a cada posible resultado y la estimación de estas probabilidades es precisamente el objetivo de este proyecto. Tampoco se permite el uso de variables ya calculadas, es decir, **el enriquecimiento debe limitarse a datos en bruto**, como por ejemplo, información sobre los jugadores, el entrenador, el estadio, el clima, datos económicos de los equipos, etc. Si tiene dudas sobre si una fuente de datos es válida o no, no dude en contactar con el profesor.

2.4. Ingeniería de variables temporales

A partir de este conjunto de datos, se deben construir nuevas variables que capturen la trayectoria de cada equipo. La tabla 2 muestra un ejemplo de cómo podría quedar un conjunto de datos enriquecido con variables temporales. El conjunto de datos de ejemplo es muy básico, es posible crear muchas más variables de diferente naturaleza, usando los datos proporcionados y más aún si se incluyen datos externos. Adicionalmente, muchas de estas variables están calculadas a partir de los últimos N partidos (3 en el ejemplo), por lo que modificando el valor N se pueden obtener diferentes versiones del mismo *concepto* de variable.

Tabla 2: Ejemplo de conjunto de datos enriquecido con variables temporales

match id full	date	season end year	home team	away team	home pts cum	home gd cum	home form last 3	home gf avg last 3	home ga avg last 3	away pts cum	away gd cum	away form last 3	away gf avg last 3	away ga avg last 3	result
11385-2223-ENGI	2023-02-04	2023	Everton	Arsenal	15	-13	0	0.667	2.667	50	29	7	1.667	0.667	2
11386-2223-ENGI	2023-02-04	2023	Aston Villa	Leicester	28	-4	7	1.333	0.667	18	-7	1	0.667	1.667	1
11387-2223-ENGI	2023-02-04	2023	Brentford	Southampton	30	4	7	1.667	0.333	15	-18	3	0.667	1	2
11388-2223-ENGI	2023-02-04	2023	Brighton	Bournemouth	31	10	7	3	1	17	-23	1	0.333	2	2
11389-2223-ENGI	2023-02-04	2023	Man United	Crystal Palace	39	7	4	1.667	1.667	24	-9	2	0.333	0.667	2

Nótese que sobre el conjunto de datos de la tabla 2 es necesario aplicar el preprocesado básico que requieran los algoritmos de aprendizaje, como puede ser el tratamiento de variables categóricas o la normalización. Adicionalmente, querrá eliminar la mayor parte de identificadores de los partidos (queremos que nuestros modelos aprendan patrones no que se limiten a memorizar los partidos).

A continuación se proporciona una descripción de las variables de ejemplo que se muestran en la tabla 2:

Descripción breve de columnas

- **home pts cum:** Puntos del equipo local antes del partido.
- **home gd cum:** Diferencia de goles acumulada del equipo local antes del partido.
- **home form last 3:** Puntos del equipo local en sus últimos 3 partidos.
- **home gf avg last 3:** Promedio de goles a favor del equipo local en sus últimos 3 partidos.
- **away pts cum:** Puntos acumulados del equipo visitante antes del partido.
- **away gd cum:** Diferencia de goles acumulada del equipo visitante antes del partido.
- **away ga avg last 3:** Promedio de goles en contra del visitante en sus últimos 3 partidos.

2.5. El problema de filtrar información

Un problema frecuente cuando trabajamos con datos temporales es *filtrar*, en el conjunto de entrenamiento, información que no estaría disponible en el momento de realizar la predicción. Este problema se conoce como *data leakage*. Por ejemplo, si en el conjunto de prueba tenemos que predecir el resultado de un partido que se va a jugar el 10 de enero de 2023, en el conjunto de entrenamiento no podemos incluir información sobre un partido que se haya jugado el 17 de enero de 2023. Las variables que describen este segundo partido podrían contener, de forma directa o indirecta, información sobre el resultado del partido del 10 de enero.

Existen varios tipos de filtración de información:

- **Filtración en conjunto de entrenamiento:** Incluir partidos **futuros** en el conjunto de entrenamiento. Debe existir una división temporal clara entre el conjunto de entrenamiento (pasado) y el conjunto de prueba (futuro). La filtración ocurre cuando el conjunto de entrenamiento contiene partidos que se han jugado después de los del conjunto de prueba.
- **Filtración de información en el cálculo de atributos:** Usar en el cálculo de variables, información que no estaba disponible antes del inicio del mismo, como por ejemplo, el número de goles marcados por cada equipo, el resultado tras la primera mitad o el número de tiros a puerta, tarjetas o faltas de ese partido (esta información solo puede usarse para calcular, por ejemplo, promedios de tarjetas o faltas en los últimos N partidos anteriores al actual). Una versión más sutil de este tipo de filtración, es la que se produce al usar información de partidos futuros para calcular variables temporales. Es decir, al calcular, para una fecha concreta, algún agregado (goles, puntos, etc.) usamos información de un partido que se ha jugado después de esa fecha.

Como **conclusión**, a la hora de diseñar nuestros experimentos debemos asegurarnos de que:

- El conjunto de entrenamiento contenga partidos anteriores a los del conjunto de prueba.
- El cálculo de variables de cada partido solo usa información que está disponible antes del instante de inicio del mismo.

2.6. Metodología general de modelado predictivo

Una vez que se ha construido un conjunto de datos enriquecido con variables temporales capaces de capturar la trayectoria reciente de cada equipo y otras características relevantes, se puede proceder a la fase de modelado predictivo. El proceso hasta obtener modelos definitivos se puede descomponer en las siguientes fases (ver Figura 1):

- **Preprocesado de datos:** Tratamiento de valores faltantes, codificación de variables categóricas, normalización, etc.
- **Reducción de la dimensión y selección de características:** Durante el proceso de construcción del conjunto de datos, es posible que se hayan creado muchos atributos, de hecho, no es malo. Sin embargo, no podemos saber a priori cuáles de ellos son relevantes para el modelo. Es el momento de responder a preguntas como *¿A la hora de calcular la racha de victorias es mejor considerar los últimos 3 partidos, o los últimos 5?*
- **Optimización de hiperparámetros:** Ajuste de los hiperparámetros de cada uno de los algoritmos candidatos en busca de los modelos con la configuración óptima. Además de la búsqueda en rejilla (grid search) estudiada en clase, existen otras técnicas de optimización más eficientes como la búsqueda aleatoria (random search) o la optimización bayesiana.
- **Evaluación final de modelos:** Una vez que se han identificado los mejores modelos, es el momento de realizar una evaluación final de los mismos sobre el conjunto de prueba si es que se ha reservado alguno. También entrenaremos modelos finales para generar las predicciones que subiremos a la competición de Kaggle.

El desarrollo de modelos predictivos es un proceso iterativo con infinitud de posibilidades. A continuación se enumeran ejemplos de decisiones que se pueden tomar a lo largo del proceso:

- Reconsiderar el conjunto de datos. Es posible probar diferentes versiones del conjunto de variables temporales y/o diferentes formas de preprocesar los datos.
- Sabemos que no debemos incluir identificadores de filas, pero ¿es útil incluir los nombres de los equipos (codificados de alguna forma) en el conjunto de datos?
- Podemos crear un modelo solo para La Liga y otro para la Premier, o uno para ambas ligas. En el primer caso, debemos concatenar las predicciones de ambos modelos a la hora de enviarlas a la competición de Kaggle.
- ¿Cuántas temporadas incluir en cada conjunto de entrenamiento? ¿Es mejor tener un conjunto de entrenamiento más grande o es preferible limitarlo a la información más reciente? No es necesario usar todas las temporadas disponibles.
- Realizar un *stacking* de modelos, es decir, combinar el poder predictivo de varios modelos.
- Existen muchos tipos de algoritmos de aprendizaje automático, cada uno con sus ventajas e inconvenientes. ¿Cuál es el más adecuado para nuestro problema?
- ¿Optimizar hiperparámetros y luego seleccionar variables o al revés? El resultado de ambos procesos es interdependiente.

Internet está lleno de recursos, tutoriales, artículos y proyectos sobre ciencia de datos relacionados con el objetivo de este trabajo, en particular. También existen numerosos libros y manuales de acceso libre. Se espera que los estudiantes exploren estos recursos para aprender e inspirarse. Si necesita ayuda para encontrar información sobre algún tema concreto, no dude en contactar con el profesor.

2.7. Metodología de evaluación




Figura 2: Esquema de validación para series temporales (walk forward validation).

Debido al riesgo de filtración de información, la división en conjuntos de entrenamiento y prueba debe realizarse respetando la naturaleza temporal de los datos. De esto se deduce que el uso de la técnica de **validación cruzada** no es una opción válida ya que está basada en divisiones aleatorias de los datos.

Para realizar una evaluación robusta (similar a validación cruzada) de nuestro modelo, respetando la naturaleza temporal de los datos, usamos lo que se conoce como **walk forward validation** y que se muestra en la Figura 2. Como se puede ver, es buena práctica reservar una o dos temporadas al final del periodo seleccionado, para realizar una última evaluación de los modelos. Estas temporadas no deben usarse durante el proceso de selección y optimización de modelos.

En este enlace encontrará un simulador que le permitirá entender el proceso de walk forward validation y sus variantes (ventana deslizante o ventana expansiva). La elección del tipo de ventana y del tamaño de los periodos de entrenamiento y prueba (y la frecuencia de reentrenamiento) son decisiones que impactan sobre los resultados y deben ser exploradas durante el proceso de modelado.

2.8. Métricas de evaluación

Se han estudiado diferentes métricas de evaluación, cada una con su propósito. Además existen otras métricas de clasificación que no se han estudiado en clase. Se recomienda usar varias métricas a la hora de explorar el rendimiento de los modelos finales, para entender mejor sus fortalezas y debilidades.

Estamos acostumbrados a que los modelos de clasificación produzcan predicciones de clase, es decir, etiquetas discretas (1, X, 2 en el caso del fútbol), sin embargo, la mayoría de los algoritmos de aprendizaje automático estiman probabilidades, y a partir de estas se asignan las etiquetas de clase (por defecto la clase con mayor probabilidad).

Es posible que tengamos un modelo que produzca buenas probabilidades pero que estén *mal calibradas* y esto se traduzca en un bajo desempeño a la hora de predecir valores de clasificación. Calibrar las probabilidades a posteriori para que se conviertan en buenas predicciones de clase es mucho más sencillo que construir un buen modelo. Teniendo en cuenta esto, existen dos tipos de métricas de evaluación para clasificación:

- **Métricas de evaluación de probabilidades:** Estas métricas evalúan la calidad de las probabilidades producidas por el modelo. Se recomienda usar estas métricas a la hora de seleccionar variables, algoritmos y modelos y tomar decisiones sobre los datos. Las más populares son la entropía cruzada, el área bajo la curva ROC (AUC-ROC) o el área bajo la curva de Precision-Recall (AUC-PR).
- **Métricas de evaluación de valores de clasificación:** Evalúan la calidad de las etiquetas de clase (1, X, 2) asignadas por el modelo. Por ejemplo, precision, recall, medida F1, tasa de aciertos, tasa de aciertos balanceada, etc.

Se recomienda tener en cuenta las métricas que se usarán para evaluar las soluciones en las competiciones de Kaggle.

2.9. Reducción de la dimensión y selección de características

Reducir la dimensión (en número de columnas) del conjunto de datos es una tarea importante a la hora de construir modelos predictivos, ya que aumenta la capacidad de generalización de los algoritmos y, por tanto, reduce el riesgo de sobreajuste, además del tiempo de entrenamiento. Existen dos grandes familias de técnicas para reducir la dimensión de los datos:

- **Técnicas de selección de características:** Estas técnicas seleccionan un subconjunto de las variables originales que son más relevantes para el modelo. Algunas de las más importantes son la selección secuencial de variables (SFS), la selección recursiva de variables (RFE) o la selección basada en importancias por permutación. Existen muchos otros métodos que puede explorar, incluso puede usar más de uno.
- **Técnicas de reducción de la dimensión:** Estas técnicas transforman el espacio original de variables en un nuevo espacio de menor dimensión, buscando preservar la mayor cantidad de información posible. Es decir, en lugar de eliminar variables completas, eliminan información redundante de los atributos y la información relevante la conservan en un menor número de dimensiones. Por ejemplo, Análisis de Componentes Principales (PCA) o t-SNE.

Importante: El uso de estas técnicas es obligatorio y según la convocatoria a la que se presente deberá usar un bloque u otro:

- Primera convocatoria: Técnicas de selección de características.
- Segunda y tercera convocatoria: Técnicas de reducción de la dimensión.

Sea cual sea su convocatoria, los estudiantes pueden explorar ambas posibilidades si lo consideran oportuno. Por último, tenga en cuenta que el uso de estas técnicas no va a garantizar una mejora en el rendimiento de los modelos, por lo que no es obligatorio incluirlas en el modelo final. Sin embargo, si ha generado muchas variables, algunas redundantes, lo normal es que se produzca una mejora tanto en la capacidad predictiva como en el tiempo de entrenamiento.

2.10. Competiciones de Kaggle

Para motivar a los estudiantes a mejorar sus modelos, se organizarán dos competencias de Kaggle, que permitirán a los diferentes equipos competir entre sí, comparando sus soluciones.

Kaggle es la plataforma de referencia para competencias de ciencia de datos. Adicionalmente es uno de los mejores recursos para aprender sobre ciencia de datos así como un gran repositorio de conjuntos de datos de cualquier ámbito.

En la sección 2.8 se comentó que las *métricas basadas en probabilidad* son más informativas a la hora de valorar el rendimiento de los modelos. Sin embargo, dado que el objetivo de este trabajo es predecir resultados de partidos de fútbol (1, X, 2), de poco sirve disponer de buenas probabilidades pero malas predicciones de etiquetas de clase. Por este motivo se propondrán dos competencias:

- **Competición de probabilidades:** Esta será la competición principal, en la que se evaluará la calidad de las probabilidades estimadas por los modelos desarrollados.
 - **Temporadas de evaluación:** 2023-2024 y 2024-2025.
 - **Métrica de evaluación:** Área bajo la curva Precision-Recall (AUC-PR). También conocida como Average Precision (AP). Al calcular la métrica se usará la opción *macro* (media sin ponderar).
 - Disponible desde el inicio del trabajo. **El enlace de la competición se publicará próximamente.**
 - Permite un mayor número de envíos diarios por equipo.
- **Competición de clasificación:** En esta competición se evaluará la capacidad de los modelos para predecir resultados de partidos (1, X, 2). Debe considerarse como una competición final, en la que se presenten las mejores configuraciones obtenidas.
 - **Temporada de evaluación:** 2025-2026.
 - **Métrica de evaluación:** Medida F1 (F1-score). Al calcular la métrica se usará la opción *macro* (media sin ponderar).
 - Los datos de la temporada 2025-2026 y la competición se publicarán más adelante.
 - Permite un número limitado de envíos diarios por equipo.

Algunas observaciones importantes sobre las competencias:

- Los miembros de cada grupo de trabajo se inscribirán a la competición en un único equipo que irá identificado con su número de grupo. Los usuarios inscritos que no puedan ser identificados, podrán ser excluidos de la competición.
- Bajo ningún concepto deben usarse los datos de las temporadas 2023-2024, 2024-2025 y 2025-2026 durante el desarrollo y optimización de modelos.
- Se conocen los resultados de los partidos que se usarán en la competición y por tanto, es posible hacer trampas. Los estudiantes son responsables de evitar filtración de datos (ver sección 2.5), ya sea de forma intencionada o accidental (muy frecuente).
- Cualquier solución que se presente a la competición debe ser reproducible y debe estar debidamente documentada. También se proporcionará la experimentación que ha conducido a las mejores configuraciones presentadas.
- Para evitar el sobreajuste, las competencias de Kaggle constan de una clasificación pública y una clasificación privada:

- Clasificación pública: Está disponible desde el inicio de la competición y se calcula sobre una parte de los datos de prueba (el 50 %). Esta clasificación sirve de orientación y permite a los estudiantes comparar el rendimiento de sus modelos con los de otros estudiantes y tomar decisiones sobre cómo mejorar sus modelos.
- Clasificación privada: Está disponible al final de la competición y se calcula con el resto de los datos de prueba (el otro 50 %). Esta clasificación se calcula con las dos o tres mejores soluciones elegidas por los estudiantes y será la que determine la clasificación final en la competición.

3. Entrega y evaluación

3.1. Documentación

El trabajo deberá documentarse siguiendo un formato de artículo científico, con una extensión mínima de 6 páginas. En la página web de la asignatura se pueden encontrar plantillas donde se sugiere una estructura general. Estas plantillas siguen el formato de los IEEE conference proceedings, cuyo sitio web guía para autores ofrece información más detallada. El documento entregado deberá estar en formato PDF. Se valorará el uso del sistema LaTeX.

La estructura general del documento debe ser la siguiente: en primer lugar, realizar una introducción al trabajo explicando el objetivo fundamental, incluyendo un breve repaso de antecedentes en relación con la temática del trabajo y las diferentes técnicas y algoritmos usados. Es importante que documente cualquier recurso externo (proyectos, repositorios, tutoriales, artículos o libros) que haya sido relevante durante la realización del trabajo.

A continuación, debe describir la metodología seguida para encontrar las mejores soluciones y documentar toda la experimentación que le ha llevado a la misma. Analice los resultados obtenidos y compare los diferentes experimentos realizados. Por último, el documento debe incluir una sección de conclusiones, y una bibliografía donde aparezcan cualquier documento consultado durante la realización del trabajo (incluidas las referencias web a páginas o repositorios).

3.2. Entrega

La entrega del trabajo consistirá en un único archivo comprimido .zip con:

- La memoria en formato PDF.
- El código implementado. La naturaleza del trabajo, basado en experimentación y análisis de resultados hace que sea necesario el uso de cuadernos de código (archivos .ipynb) que combinan celdas de código Python con celdas de texto Markdown. Por tanto, los cuadernos de código, debidamente documentados, serán el elemento principal. Podrá utilizar archivos .py para almacenar funciones o clases auxiliares (debidamente documentadas) que use en sus cuadernos. Los cuadernos deben contener celdas de código que permitan reproducir los principales resultados obtenidos.
- Cualquier conjunto de datos o archivo que sea necesario para ejecutar su código. Es importante usar rutas relativas para que el profesor pueda ejecutar el cuaderno en otro ordenador sin modificar el código.
- Los conjuntos de datos usados para entrenar el modelo final de las soluciones definitivas seleccionadas en la competición. También debe proporcionar los archivos con las predicciones de las soluciones seleccionadas en la competición.

El código y los experimentos realizados deben estar debidamente documentados, las decisiones tomadas debidamente justificadas y los resultados obtenidos deben ser interpretados.

3.3. Presentación y defensa

El día de la defensa se deberá realizar una breve presentación (PDF, PowerPoint o similar) de 10 minutos en la que participarán activamente todos los miembros del grupo que ha desarrollado el trabajo. No es necesario entregar la presentación. Esta presentación seguirá, a grandes rasgos, la misma estructura que el documento, pero se deberá hacer especial mención a los resultados obtenidos y al análisis crítico de los mismos. Se podrá usar un portátil (personal del alumno), diapositivas y/o pizarra. En los siguientes 10 minutos de la defensa, el profesor realizará preguntas sobre el trabajo, que podrán ser tanto del documento como del código fuente. Adicionalmente, el profesor podrá proporcionar un nuevo conjunto de datos con el que probar el algoritmo implementado.

3.4. Criterios de evaluación

Para la evaluación del trabajo se tendrán en cuenta los siguientes criterios, considerando una nota total máxima de 3 puntos:

- Diseño, metodología y código fuente (1 punto): Se valorará la claridad y buen estilo de programación. Se tendrá en cuenta la originalidad de la solución implementada (ingeniería de variables y proceso de desarrollo de modelos). Se tendrá en cuenta la calidad de la documentación del código y su capacidad para ser ejecutado por un tercero sin necesidad de realizar modificaciones.
- Experimentación y resultados (1 punto): Con respecto a la experimentación, se valorará la calidad y completitud de los experimentos realizados y de alternativas probadas. Además, se tendrá en cuenta (solo de forma positiva) el rendimiento de los modelos obtenidos. Es importante que los experimentos realizados y los resultados obtenidos hayan sido documentados e interpretados. No se tendrán en cuenta aquellos resultados experimentales que no sean reproducibles.
- Artículo científico (1 punto): Se valorará el uso adecuado del lenguaje y el estilo general del documento (por ejemplo, el uso de la plantilla sugerida). Se valorará en general la claridad de las explicaciones, el razonamiento de las decisiones, y especialmente el análisis y presentación de resultados en las secciones de experimentación y conclusiones.
- Presentación y defensa: se valorará la claridad de la presentación y la buena explicación de los contenidos del trabajo así como las respuestas a las preguntas realizadas por el profesor. Esto dará lugar, para cada alumno por separado, a un factor multiplicativo en el intervalo $[0, 1]$ de la nota total obtenida a partir de los apartados anteriores.
- La posición en el ranking se tendrá en cuenta a la hora de valorar el trabajo aunque siempre de forma positiva, nunca negativa. Un trabajo muy completo, podrá alcanzar la máxima nota aunque no haya alcanzado una buena posición en el ranking. Al final de la competición los estudiantes seleccionarán (en Kaggle) entre 2 y 3 soluciones para su evaluación final. Estas soluciones deben ser reproducibles y la metodología seguida para obtenerlas debe estar debidamente documentada.

3.5. Inteligencia artificial generativa, recursos externos y plagio

Se trata de un proyecto abierto que busca soluciones completas, creativas e innovadoras. Por tanto, se anima a los estudiantes a explorar recursos externos, como tutoriales, artículos, libros o proyectos de código abierto relacionados con el objetivo del trabajo.

De la misma forma, el uso de sistemas de inteligencia artificial generativa está permitido siempre que se indique cómo se han usado.

Cualquier recurso externo que se use durante la realización del trabajo debe ser citado convenientemente en el documento final y en el cuaderno de código si es conveniente.

En la defensa del trabajo ambos alumnos deben demostrar conocimiento y entendimiento de la totalidad del trabajo, lo que incluye las respuestas obtenidas de esos sistemas, así como los recursos externos utilizados. Es muy importante que los alumnos sean capaces de explicar las decisiones metodológicas y de diseño tomadas.

Cualquier plagio (no es lo mismo usar recursos externos que entregar código de terceros como propio), compartición de código o uso de material que no sea original y del que no se cite convenientemente la fuente, significará automáticamente la calificación de cero en la asignatura para todos los alumnos involucrados. Por tanto, a estos alumnos no se les conserva, ni para la actual ni para futuras convocatorias, ninguna nota que hubiesen obtenido hasta el momento. Todo ello sin perjuicio de las correspondientes medidas disciplinarias que se pudieran tomar.